Natural Language Processing with PyTorch
-3장-

정 시 열

목차

1.퍼셉트론

퍼셉트론
: 가장 간단한 신경망, 생물학적 뉴런을 본 따서 만듦

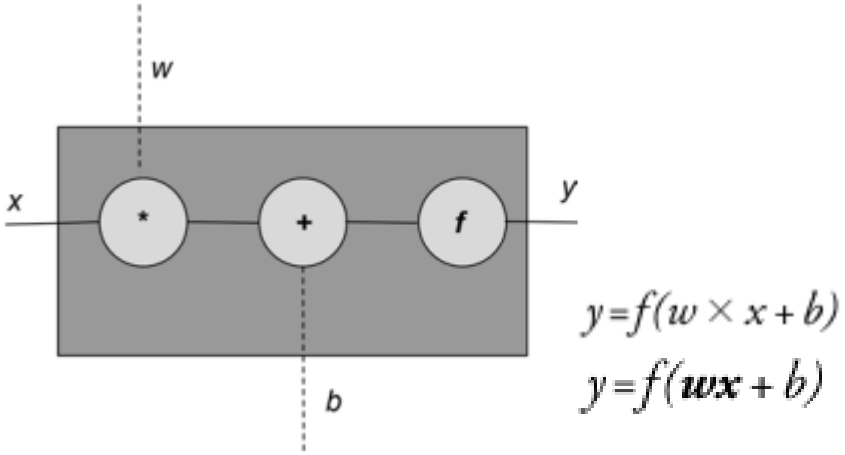

그림 3-1 입력(x)과 출력(y)이 있는 퍼셉트론의 계산 그래프. 모델의 파라미터는 가중치(w)와 절편(b)입니다.

코드 3-1 파이토치로 구현한 퍼셉트론

```
import torch
import torch.nn as nn

class Perceptron(nn.Module):
    """ 퍼셉트론은 하나의 선형 층입니다 """
    def __init__(self, input_dim):
        """
        매개변수:
            input_dim (int): 입력 특성의 크기
        """
        super(Perceptron, self).__init__()
        self.fc1 = nn.Linear(input_dim, 1)

    def forward(self, x_in):
        """퍼셉트론의 정방향 계산

        매개변수:
            x_in (torch.Tensor): 입력 데이터 텐서
                x_in.shape는 (batch, num_features)입니다.
        반환값:
            결과 텐서. tensor.shape는 (batch,)입니다.
        """
        return torch.sigmoid(self.fc1(x_in)).squeeze()
```

2.활성화 함수

활성화 함수
: 비선형 함수로, 데이터의 복잡한 관계를 감지하는데 사용

2.1 Sigmoid
: 임의의 실숫값을 받아 0~1 사이의 범위로 압축

$$f(x) = \frac{1}{1 + e^{-x}}$$

코드 3-2 시그모이드 활성화 함수

```
import torch
import matplotlib.pyplot as plt

x = torch.range(-5., 5., 0.1)
y = torch.sigmoid(x)
plt.plot(x.numpy(), y.numpy())
plt.show()
```

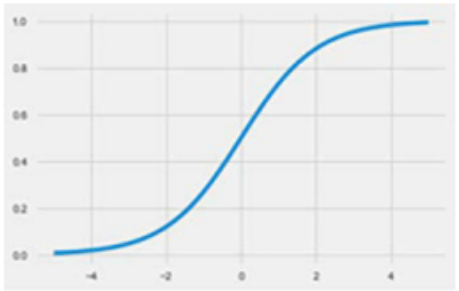

2.2 tanh
: 임의의 실숫값을 받아 -1~1사이의 범위로 압축

$$f(x) = tanh\ x = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

코드 3-3 하이퍼볼릭 탄젠트 활성화 함수

```
import torch
import matplotlib.pyplot as plt

x = torch.range(-5., 5., 0.1)
y = torch.tanh(x)

plt.plot(x.numpy(), y.numpy())
plt.show()
```

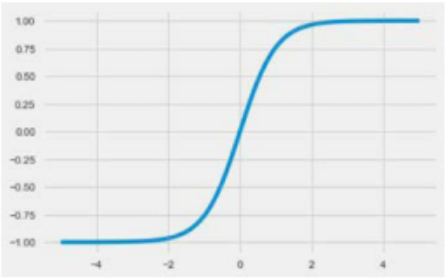

2.활성화 함수

2.3 RELU

: 음수값을 0으로 자른다는 특징

$$f(x) = max(0,\ x)$$

코드 3-4 렐루 활성화 함수

```
import torch
import matplotlib.pyplot as plt

relu = torch.nn.ReLU()
x = torch.range(-5., 5., 0.1)
y = relu(x)

plt.plot(x.numpy(), y.numpy())
plt.show()
```

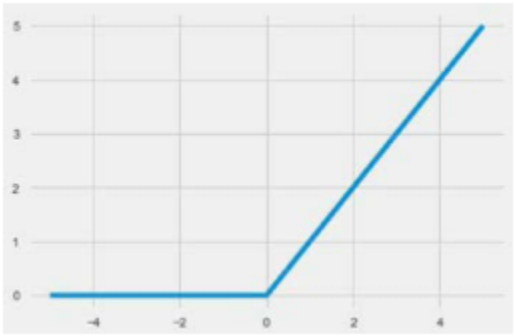

2.4 PRELU

: RELU의 단점을 줄이기 위해 고안

$$f(x) = max(x,\ ax)$$

코드 3-5 PReLU 활성화 함수

```
import torch
import matplotlib.pyplot as plt

prelu = torch.nn.PReLU(num_parameters=1)
x = torch.range(-5., 5., 0.1)
y = prelu(x)

plt.plot(x.numpy(), y.numpy())
plt.show()
```

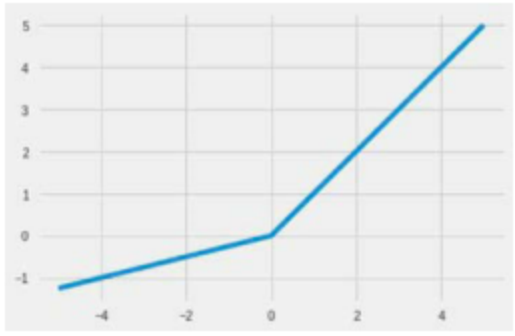

2.활성화 함수

2.5 Softmax

: 임의의 실숫값을 받아 0~1 사이의 범위로 압축

$$softmax(x_i) = \frac{e^{x_i}}{\sum_{f=1}^{k} e^{x_f}}$$

코드 3-6 소프트맥스 활성화 함수

```
In[0]  import torch.nn as nn
       import torch

       softmax = nn.Softmax(dim=1)
       x_input = torch.randn(1, 3)
       y_output = softmax(x_input)
       print(x_input)
       print(y_output)
       print(torch.sum(y_output, dim=1))

Out[0] tensor([[ 0.5836, -1.3749, -1.1229]])
       tensor([[ 0.7561,  0.1067,  0.1372]])
       tensor([ 1.])
```

3. 손실 함수

3.1 MSE

$$L_{MSE}(y, \hat{y}) = \frac{1}{n}\sum_{i=1}^{n}(y - \hat{y})^2$$

코드 3-7 평균 제곱 오차 손실

```
In[0]  import torch
       import torch.nn as nn

       mse_loss = nn.MSELoss()
       outputs = torch.randn(3, 5, requires_grad=True)
       targets = torch.randn(3, 5)
       loss = mse_loss(outputs, targets)
       print(loss)

Out[0] tensor(3.8618)
```

3.2 Categorical Cross-Entropy

$$L_{cross\_entropy}(y, \hat{y}) = -\sum_{i} y_i \log(\hat{y}_i)$$

코드 3-8 크로스 엔트로피 손실

```
In[0]  import torch
       import torch.nn as nn

       ce_loss = nn.CrossEntropyLoss()
       outputs = torch.randn(3, 5, requires_grad=True)
       targets = torch.tensor([1, 0, 3], dtype=torch.int64)
       loss = ce_loss(outputs, targets)
       print(loss)

Out[0] tensor(2.7256)
```

4. 지도 학습

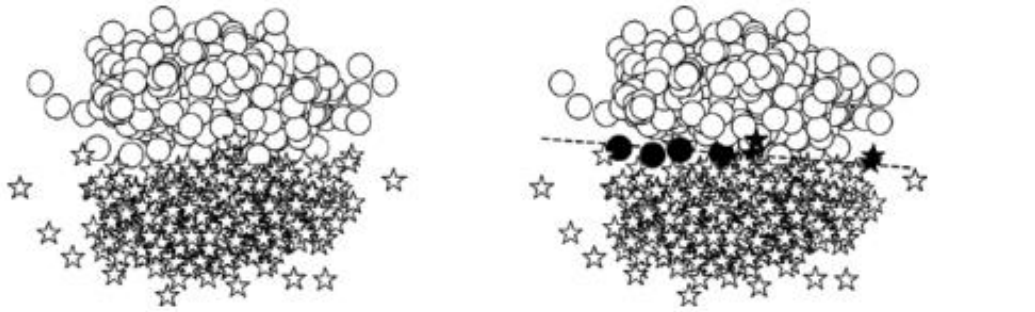

그림 3-2 선형적으로 구분할 수 있는 예제 데이터 만들기. 이 데이터셋은 (클래스마다 하나씩) 정규 분포 두 개에서 샘플링했습니다. 이 분류 작업은 데이터 포인트가 두 분포 중 어디에 속하는지 구별하는 작업입니다.

1. 모델 선택
   - 퍼셉트론 사용
   - 클래스에 인덱스 할당 (0/1)
   - 활성화 함수: 시그모이드
   - 출력값: 데이터가 클래스 1일 확률
2. 확률을 클래스로 변환
   - 일반적으로 결정 경계: 0.5
   - 만족스러운 precision을 위해서는 valid dataset으로 튜닝
3. 손실 함수 선택
   - 손실함수: Binary Cross-Entropy
4. 옵티마이저 선택
   - Adam 사용
5. 결합

4. 훈련 개념

1. 평가 지표
   -정확도 등

2. 일반화
   -데이터셋 분할 (같은 class 비율)
   - K-fold

3. 훈련 중지 시점
   - Early Stopping

4. 최적의 하이퍼 파라미터
   - 여러 옵션을 체계적으로 테스트

5. 규제
   - 합리적인 표현 선택을 도와줌

5. 예제

- 옐프 데이터 셋을 활용한 감성 분류

코드 3-12 훈련, 검증, 테스트 세트 만들기

```
# 별점 기준으로 나누어 훈련, 검증, 테스트를 만듭니다.
by_rating = collections.defaultdict(list)
for _, row in review_subset.iterrows():
    by_rating[row.rating].append(row.to_dict())

# 분할 데이터를 만듭니다.
final_list = []
np.random.seed(args.seed)

for _, item_list in sorted(by_rating.items()):
    np.random.shuffle(item_list)
    n_total = len(item_list)
    n_train = int(args.train_proportion * n_total)
    n_val = int(args.val_proportion * n_total)
    n_test = int(args.test_proportion * n_total)

    # 데이터 포인터에 분할 속성을 추가합니다
    for item in item_list[:n_train]:
        item['split'] = 'train'

    for item in item_list[n_train:n_train+n_val]:
        item['split'] = 'val'

    for item in item_list[n_train+n_val:n_train+n_val+n_test]:
        item['split'] = 'test'

    # 최종 리스트에 추가합니다
    final_list.extend(item_list)

final_reviews = pd.DataFrame(final_list)
```

코드 3-13 최소한의 데이터 정제 작업

```
def preprocess_text(text):
    text = text.lower()
    text = re.sub(r"([.,!?])", r" \1 ", text)
    text = re.sub(r"[^a-zA-Z.,!?]+", r" ", text)
    return text

final_reviews.review = final_reviews.review.apply(preprocess_text)
```

5. 예제

- Dataset 구현

코드 3-14 옐프 리뷰 데이터를 위한 파이토치 데이터셋 클래스[26]

```
from torch.utils.data import Dataset

class ReviewDataset(Dataset):
    def __init__(self, review_df, vectorizer):
        """
        매개변수:
            review_df (pandas.DataFrame): 데이터셋
            vectorizer (ReviewVectorizer): ReviewVectorizer 객체
        """
        self.review_df = review_df
        self._vectorizer = vectorizer

        self.train_df = self.review_df[self.review_df.split=='train']
        self.train_size = len(self.train_df)

        self.val_df = self.review_df[self.review_df.split=='val']
        self.validation_size = len(self.val_df)

        self.test_df = self.review_df[self.review_df.split=='test']
        self.test_size = len(self.test_df)

        self._lookup_dict = {'train': (self.train_df, self.train_size),
                             'val': (self.val_df, self.validation_size),
                             'test': (self.test_df, self.test_size)}

        self.set_split('train')

    @classmethod
    def load_dataset_and_make_vectorizer(cls, review_csv):
        """데이터셋을 로드하고 새로운 ReviewVectorizer 객체를 만듭니다

        매개변수:
            review_csv (str): 데이터셋의 위치
        반환값:
            ReviewDataset의 인스턴스
        """
        review_df = pd.read_csv(review_csv)
        return cls(review_df, ReviewVectorizer.from_dataframe(review_df))

    def get_vectorizer(self):
        """ ReviewVectorizer 객체를 반환합니다 """
        return self._vectorizer

    def set_split(self, split="train"):
        """ 데이터프레임에 있는 열을 사용해 분할 세트를 선택합니다

        매개변수:
            split (str): "train", "val", "test" 중 하나
        """
        self._target_split = split
        self._target_df, self._target_size = self._lookup_dict[split]

    def __len__(self):
        return self._target_size

    def __getitem__(self, index):
        """ 파이토치 데이터셋의 주요 진입 메서드

        매개변수:
            index (int): 데이터 포인트의 인덱스
        반환값:
            데이터 포인트의 특성(x_data)과 레이블(y_target)로 이루어진 딕셔너리
        """
        row = self._target_df.iloc[index]

        review_vector = \
            self._vectorizer.vectorize(row.review)

        rating_index = \
            self._vectorizer.rating_vocab.lookup_token(row.rating)

        return {'x_data': review_vector,
                'y_target': rating_index}

    def get_num_batches(self, batch_size):
        """ 배치 크기가 주어지면 데이터셋으로 만들 수 있는 배치 개수를 반환합니다

        매개변수:
            batch_size (int)
        반환값:
            배치 개수
        """
        return len(self) // batch_size
```

5. 예제

- Vocabulary 구현

코드 3-15 머신러닝 파이프라인에 필요한 토큰과 정수 매핑을 관리하는 Vocabulary 클래스[29]

```
class Vocabulary(object):
    """ 매핑을 위해 텍스트를 처리하고 어휘 사전을 만드는 클래스 """

    def __init__(self, token_to_idx=None, add_unk=True, unk_token="<UNK>"):
        """
        매개변수:
            token_to_idx (dict): 기존 토큰-인덱스 매핑 딕셔너리
            add_unk (bool): UNK 토큰을 추가할지 지정하는 플래그
            unk_token (str): Vocabulary에 추가할 UNK 토큰
        """

        if token_to_idx is None:
            token_to_idx = {}
        self._token_to_idx = token_to_idx

        self._idx_to_token = {idx: token
                              for token, idx in self._token_to_idx.items()}

        self._add_unk = add_unk
        self._unk_token = unk_token

        self.unk_index = -1
        if add_unk:
            self.unk_index = self.add_token(unk_token)


    def to_serializable(self):
        """ 직렬화할 수 있는 딕셔너리를 반환합니다 """
        return {'token_to_idx': self._token_to_idx,
                'add_unk': self._add_unk,
                'unk_token': self._unk_token}

    @classmethod
    def from_serializable(cls, contents):
        """ 직렬화된 딕셔너리에서 Vocabulary 객체를 만듭니다 """
        return cls(**contents)

    def add_token(self, token):
        """ 토큰을 기반으로 매핑 딕셔너리를 업데이트합니다

        매개변수:
            token (str): Vocabulary에 추가할 토큰
        반환값:
            index (int): 토큰에 상응하는 정수
        """
        if token in self._token_to_idx:
            index = self._token_to_idx[token]
        else:
            index = len(self._token_to_idx)
            self._token_to_idx[token] = index
            self._idx_to_token[index] = token
        return index

    def lookup_token(self, token):
        """ 토큰에 대응하는 인덱스를 추출합니다.
        토큰이 없으면 UNK 인덱스를 반환합니다.

        매개변수:
            token (str): 찾을 토큰
        반환값:
            index (int): 토큰에 해당하는 인덱스
        노트:
            UNK 토큰을 사용하려면 (Vocabulary에 추가하기 위해)
        `unk_index`가 0보다 커야 합니다.
        """
        if self.add_unk:
            return self._token_to_idx.get(token, self.unk_index)
        else:
            return self._token_to_idx[token]

    def lookup_index(self, index):
        """ 인덱스에 해당하는 토큰을 반환합니다.

        매개변수:
            index (int): 찾을 인덱스
        반환값:
            token (str): 인덱스에 해당하는 토큰
        에러:
            KeyError: 인덱스가 Vocabulary에 없을 때 발생합니다.
        """
        if index not in self._idx_to_token:
            raise KeyError("Vocabulary에 인덱스(%d)가 없습니다." % index)
        return self._idx_to_token[index]

    def __str__(self):
        return "<Vocabulary(size=%d)>" % len(self)

    def __len__(self):
        return len(self._token_to_idx)
```

5. 예제

- Vectorizer 구현

코드 3-16 텍스트를 수치 벡터로 변환하는 Vectorizer 클래스

```
class ReviewVectorizer(object):
    """ 어휘 사전을 생성하고 관리합니다 """
    def __init__(self, review_vocab, rating_vocab):
        """
        매개변수:
            review_vocab (Vocabulary): 단어를 정수에 매핑하는 Vocabulary
            rating_vocab (Vocabulary): 클래스 레이블을 정수에 매핑하는 Vocabulary
        """
        self.review_vocab = review_vocab
        self.rating_vocab = rating_vocab
    def vectorize(self, review):
        """리뷰에 대한 원-핫 벡터를 만듭니다

        매개변수:
            review (str): 리뷰
        반환값:
            one_hot (np.ndarray): 원-핫 벡터
        """
        one_hot = np.zeros(len(self.review_vocab), dtype=np.float32)

        for token in review.split(" "):
            if token not in string.punctuation:
                one_hot[self.review_vocab.lookup_token(token)] = 1

        return one_hot

    @classmethod
    def from_dataframe(cls, review_df, cutoff=25):
        """ 데이터셋 데이터프레임에서 Vectorizer 객체를 만듭니다

        매개변수:
            review_df (pandas.DataFrame): 리뷰 데이터셋
            cutoff (int): 빈도 기반 필터링 설정값
        반환값:
            ReviewVectorizer 객체
        """
        review_vocab = Vocabulary(add_unk=True)
        rating_vocab = Vocabulary(add_unk=False)

        # 점수를 추가합니다
        for rating in sorted(set(review_df.rating)):
            rating_vocab.add_token(rating)

        # count > cutoff인 단어를 추가합니다
        word_counts = Counter()
        for review in review_df.review:
            for word in review.split(" "):
                if word not in string.punctuation:
                    word_counts[word] += 1

        for word, count in word_counts.items():
            if count > cutoff:
                review_vocab.add_token(word)

        return cls(review_vocab, rating_vocab)

    @classmethod
    def from_serializable(cls, contents):
        """ 직렬화된 딕셔너리에서 ReviewVectorizer 객체를 만듭니다
        매개변수:
            contents (dict): 직렬화된 딕셔너리
        반환값:
            ReviewVectorizer 클래스 객체
        """
        review_vocab = Vocabulary.from_serializable(contents['review_vocab'])
        rating_vocab = Vocabulary.from_serializable(contents['rating_vocab'])

        return cls(review_vocab=review_vocab, rating_vocab=rating_vocab)

    def to_serializable(self):
        """ 캐싱을 위해 직렬화된 딕셔너리를 만듭니다

        반환값:
            contents (dict): 직렬화된 딕셔너리
        """
        return {'review_vocab': self.review_vocab.to_serializable(),
                'rating_vocab': self.rating_vocab.to_serializable()}
```

5. 예제

- DataLoader 구현

코드 3-17 데이터셋에서 미니배치 생성하기

```
from torch.utils.data import DataLoader

def generate_batches(dataset, batch_size, shuffle=True,
                     drop_last=True, device="cpu"):


"""
파이토치 DataLoader를 감싸는 제너레이터 함수.
각 텐서를 지정된 장치로 이동합니다.
"""
dataloader = DataLoader(dataset=dataset, batch_size=batch_size,
                        shuffle=shuffle, drop_last=drop_last)

for data_dict in dataloader:
    out_data_dict = {}
    for name, tensor in data_dict.items():
        out_data_dict[name] = data_dict[name].to(device)
    yield out_data_dict
```

5. 예제

- 퍼셉트론 분류기

코드 3-18 엘프 리뷰를 분류하는 퍼셉트론 분류기

```
import torch.nn as nn

class ReviewClassifier(nn.Module):
    """ 간단한 퍼셉트론 기반 분류기 """
    def __init__(self, num_features):
        """
        매개변수:
            num_features (int): 입력 특성 벡터의 크기
        """
        super(ReviewClassifier, self).__init__()
        self.fc1 = nn.Linear(in_features=num_features,
                             out_features=1)

    def forward(self, x_in, apply_sigmoid=False):
        """ 분류기의 정방향 계산

        매개변수:
            x_in (torch.Tensor): 입력 데이터 텐서
                x_in.shape는 (batch, num_features)입니다.
            apply_sigmoid (bool): 시그모이드 활성화 함수를 위한 플래그
                크로스 엔트로피 손실을 사용하려면 False로 지정합니다
        반환값:
            결과 텐서. tensor.shape은 (batch,)입니다.
        """
        y_out = self.fc1(x_in).squeeze()
        if apply_sigmoid:
            y_out = torch.sigmoid(y_out)
        return y_out
```

5. 예제

- 훈련 준비

코드 3-20 데이터셋, 모델, 손실, 옵티마이저, 훈련 상태 딕셔너리 만들기

```
import torch.optim as optim

def make_train_state(args):
    return {'epoch_index': 0,
            'train_loss': [],
            'train_acc': [],
            'val_loss': [],
            'val_acc': [],
            'test_loss': -1,
            'test_acc': -1}
train_state = make_train_state(args)

if not torch.cuda.is_available():
    args.cuda = False
args.device = torch.device("cuda" if args.cuda else "cpu")

# 데이터셋과 Vectorizer
dataset = ReviewDataset.load_dataset_and_make_vectorizer(args.review_csv)
vectorizer = dataset.get_vectorizer()

# 모델
classifier = ReviewClassifier(num_features=len(vectorizer.review_vocab))
classifier = classifier.to(args.device)

# 손실 함수와 옵티마이저
loss_func = nn.BCEWithLogitsLoss()
optimizer = optim.Adam(classifier.parameters(), lr=args.learning_rate)
```

- 훈련 반복

코드 3-21 훈련 반복

```
for epoch_index in range(args.num_epochs):
    train_state['epoch_index'] = epoch_index

    # 훈련 세트 순회
    # 훈련 세트와 배치 제너레이터 준비, 손실과 정확도를 0으로 설정
    dataset.set_split('train')
    batch_generator = generate_batches(dataset,
                                       batch_size=args.batch_size,
                                       device=args.device)
    running_loss = 0.0
    running_acc = 0.0
    classifier.train()

    for batch_index, batch_dict in enumerate(batch_generator):
        # 훈련 과정은 5단계로 이루어집니다

        # 1단계. 그레이디언트를 0으로 초기화합니다
        optimizer.zero_grad()

        # 2단계. 출력을 계산합니다
        y_pred = classifier(x_in=batch_dict['x_data'].float())

        # 3단계. 손실을 계산합니다
        loss = loss_func(y_pred, batch_dict['y_target'].float())
        loss_batch = loss.item()
        running_loss += (loss_batch - running_loss) / (batch_index + 1)

        # 4단계. 손실을 사용해 그레이디언트를 계산합니다
        loss.backward()

        # 5단계. 옵티마이저로 가중치를 업데이트합니다
        optimizer.step()
        # -----------------------------------------

        # 정확도를 계산합니다
        acc_batch = compute_accuracy(y_pred, batch_dict['y_target'])
        running_acc += (acc_batch - running_acc) / (batch_index + 1)

    train_state['train_loss'].append(running_loss)
    train_state['train_acc'].append(running_acc)

    # 검증 세트 순회
    # 검증 세트와 배치 제너레이터 준비, 손실과 정확도를 0으로 설정
    dataset.set_split('val')
    batch_generator = generate_batches(dataset,
                                       batch_size=args.batch_size,
                                       device=args.device)
    running_loss = 0.
    running_acc = 0.
    classifier.eval()

    for batch_index, batch_dict in enumerate(batch_generator):

        # 1단계. 출력을 계산합니다
        y_pred = classifier(x_in=batch_dict['x_data'].float())

        # 2단계. 손실을 계산합니다
        loss = loss_func(y_pred, batch_dict['y_target'].float())
        loss_batch = loss.item()
        running_loss += (loss_batch - running_loss) / (batch_index + 1)

        # 3단계. 정확도를 계산합니다
        acc_batch = compute_accuracy(y_pred, batch_dict['y_target'])
        running_acc += (acc_batch - running_acc) / (batch_index + 1)

    train_state['val_loss'].append(running_loss)
    train_state['val_acc'].append(running_acc)
```

5. 예제

- 테스트 세트 평가

코드 3-22 테스트 세트 평가

```
In[0]  dataset.set_split('test')
       batch_generator = generate_batches(dataset,
                                          batch_size=args.batch_size,
                                          device=args.device)
       running_loss = 0.
       running_acc = 0.
       classifier.eval()

       for batch_index, batch_dict in enumerate(batch_generator):
           # 출력을 계산합니다
           y_pred = classifier(x_in=batch_dict['x_data'].float())

           # 손실을 계산합니다
           loss = loss_func(y_pred, batch_dict['y_target'].float())
           loss_batch = loss.item()
           running_loss += (loss_batch - running_loss) / (batch_index + 1)
```

```
           # 정확도를 계산합니다
           acc_batch = compute_accuracy(y_pred, batch_dict['y_target'])
           running_acc += (acc_batch - running_acc) / (batch_index + 1)

       train_state['test_loss'] = running_loss
       train_state['test_acc'] = running_acc

In[1]  print("Test loss: {:.3f}".format(train_state['test_loss']))
       print("Test Accuracy: {:.2f}".format(train_state['test_acc']))

Out[1] Test loss: 0.297
       Test Accuracy: 90.55
```

- 추론 분류

코드 3-23 샘플 리뷰에 대한 예측 출력하기

```
In[0]  def predict_rating(review, classifier, vectorizer,
                          decision_threshold=0.5):
           """ 리뷰 점수 예측하기

           매개변수:
               review (str): 리뷰 텍스트
               classifier (ReviewClassifier): 훈련된 모델
               vectorizer (ReviewVectorizer): Vectorizer 객체
               decision_threshold (float): 클래스를 나눌 결정 경계
           """

           review = preprocess_text(review)
           vectorized_review = torch.tensor(vectorizer.vectorize(review))
           result = classifier(vectorized_review.view(1, -1))

           probability_value = torch.sigmoid(result).item()

           index = 1
           if probability_value < decision_threshold:
               index = 0
           return vectorizer.rating_vocab.lookup_index(index)
```

5. 예제

- 가중치 분석

코드 3-24 분류기의 가중치 분석하기

```
In[0]  # 가중치 정렬
       fc1_weights = classifier.fc1.weight.detach()[0]
       _, indices = torch.sort(fc1_weights, dim=0, descending=True)
       indices = indices.numpy().tolist()

       # 긍정적인 단어 상위 20개
       print("긍정 리뷰에 영향을 미치는 단어:")
       print("----------------------------------------")
       for i in range(20):
           print(vectorizer.review_vocab.lookup_index(indices[i]))


Out[0] 긍정 리뷰에 영향을 미치는 단어:
       ----------------------------------------
       great
       awesome
       amazing
       love
       friendly
       delicious
       best
       excellent
       definitely
       perfect
       fantastic
       wonderful
       vegas
       favorite
       loved
       yummy
       fresh
       reasonable
       always
       recommend

In[1]  # 부정적인 단어 상위 20개
       print("부정 리뷰에 영향을 미치는 단어:")
       print("----------------------------------------")
       indices.reverse()
       for i in range(20):
           print(vectorizer.review_vocab.lookup_index(indices[i]))

Out[1] 부정 리뷰에 영향을 미치는 단어:
       ----------------------------------------
       worst
       horrible
       mediocre
       terrible
       not
       rude
       bland
       disgusting
       dirty
       awful
       poor
       disappointing
       ok
       no
       overpriced
       sorry
       nothing
       meh
       manager
       gross
```

끝